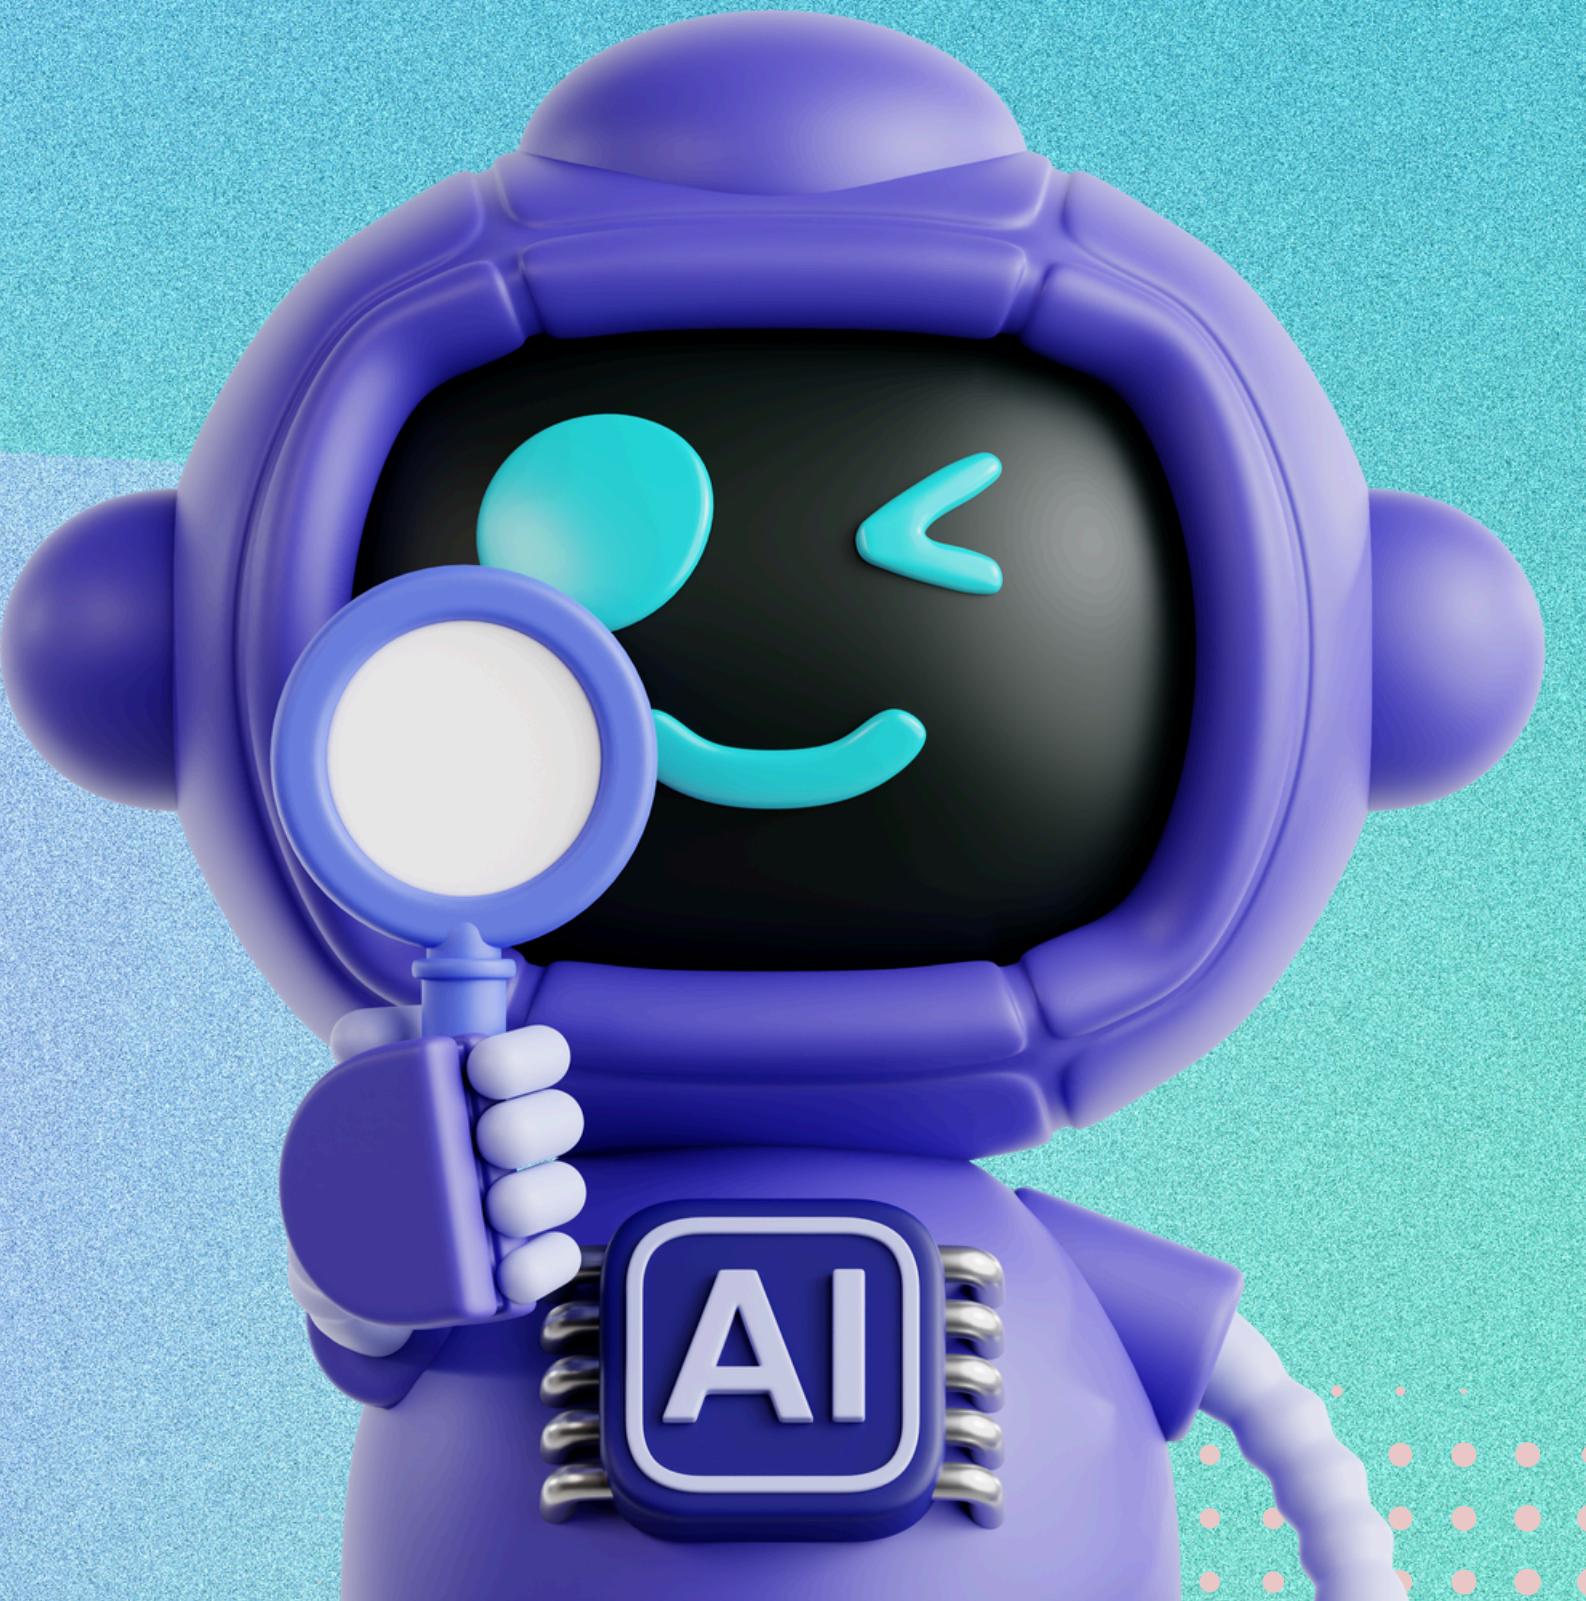


# LSTM PRESSURE PREDICTION



# PROBLEMA

Durante la pandemia de COVID-19 en 2020, la demanda de respiradores se incrementó drásticamente debido a los problemas respiratorios asociados con el SARS-CoV-2. Las limitaciones en la precisión y el costo de los materiales necesarios para controlar adecuadamente los respiradores convencionales evidenciaron la necesidad de diseños alternativos, que fueran tanto más económicos como de rápida fabricación (Uddin et al., 2024) [1].

Los controladores PID, que regulan variables industriales como temperatura, flujo, presión y velocidad, son la tecnología predominante en estos dispositivos. Sin embargo, su configuración y supervisión clínica requieren operadores especializados, lo cual limita grandemente su accesibilidad . Además, el desarrollo de nuevos métodos para controlar los ventiladores, incluyendo los PID, resulta prohibitivamente costoso, incluso antes de llegar a la fase de ensayos clínicos.



# ANÁLISIS DE LA PROBLEMÁTICA

---

## Soluciones en la Actualidad

En la actualidad, existen simuladores que se entrena como un conjunto de modelos, donde cada modelo simula una configuración única de pulmón. Sin embargo, los pulmones y sus atributos forman un espacio continuo, por lo que es necesario explorar un enfoque paramétrico que considere además las diferencias entre los pulmones de los pacientes.

## Uso de Deep Learning

Por lo tanto, para abordar estas limitaciones, proponemos automatizar el control de flujo en dispositivos respiratorios mediante un modelo de deep learning. Según Diao et al. (2024) [2], este es un problema que se puede replantear como un desafío de control en el que un modelo es entrenado con datos recolectados de respiradores con el fin de automatizar el control del flujo en estos dispositivos.

## Justificación de Uso de Deep Learning

Según la investigación de Suo et al. (2021) [3], las redes neuronales superan a los controladores PID en términos de precisión cuando se adaptan a condiciones específicas. Esto indica que el deep learning ofrece una ventaja significativa en escenarios reales donde la variabilidad de los datos es significativa.

---

**Fuentes:** Diao, S., Wei, C., Wang, J., & Li, Y. (2024). Ventilator pressure prediction using recurrent neural network. arXiv (Cornell University). <https://doi.org/10.48550/arxiv.2410.06552>  
Suo, D., Agarwal, N., Xia, W., Chen, X., Ghai, U., Yu, A., Gradi, P., Singh, K., Zhang, C., Minasyan, E., LaChance, J., Zajdel, T., Schottdorf, M., Cohen, D., & Hazan, E. (2021). Machine Learning for Mechanical Ventilation Control. arXiv (Cornell University). <https://doi.org/10.48550/arxiv.2102.06779>



# ANÁLISIS EXPLORATORIO

---

## Origen y Recopilación de los Datos

Los datos empleados en este estudio se obtuvieron de la plataforma Kaggle, mediante su página oficial, y corresponden a registros experimentales de un ventilador mecánico de código abierto. El sistema experimental consiste en un ventilador modificado conectado a un pulmón artificial, simulado mediante un fuelle. Consisten en múltiples series temporales correspondientes a ciclos respiratorios, donde cada serie representa una respiración de aproximadamente 3 segundos.

## Análisis de Variables y Estructura

Cada observación en el conjunto de datos contiene ocho variables que modelan la dinámica respiratoria. La variable `id` actúa como un identificador único por paso de tiempo, mientras que `breath_id` distingue cada ciclo de respiración. Entre las características fisiológicas, `R` mide la resistencia al flujo de aire en  $\text{cmH}_2\text{O}/(\text{L/s})$ , y `C` representa la compliance pulmonar en  $\text{mL/cmH}_2\text{O}$ , indicando la flexibilidad pulmonar. La variable `time_step` especifica el instante de cada medición, y las variables de control `u_in` y `u_out` regulan las válvulas de entrada y salida de aire, con valores que reflejan su apertura. La variable de respuesta `pressure`, medida en  $\text{cmH}_2\text{O}$ , representa la presión en las vías respiratorias, proporcionando la variable objetivo del modelo.

Nombre	Descripción	Tipo
<code>id</code>	Identificador único.	Cualitativa (Nominal)
<code>breath_id</code>	Identificador de ciclo de respiración.	Cualitativa (Nominal)
<code>R</code>	Resistencia de las vías respiratorias.	Cualitativa (Nominal)
<code>C</code>	Cumplimiento del pulmón.	Cualitativa (Nominal)
<code>time_step</code>	Marca de tiempo de cada medición.	Cuantitativa (Continua)
<code>u_in</code>	Entrada de aire en la válvula.	Cuantitativa (Continua)
<code>u_out</code>	Salida de aire en la válvula.	Cualitativa (Nominal)
<code>pressure</code>	Presión en las vías respiratorias.	Cuantitativa (Continua)

Cuadro 1 - Descripción General de Variables del Conjunto de Datos Utilizado

# PROPUESTA DE SOLUCIÓN

Como se mencionó antes, el análisis exploratorio de los datos revela una evidente estructura temporal, lo que sugiere que el problema en cuestión se clasifica como una **serie de tiempo**. Por ende, se propone una solución basada en la arquitectura LSTM, dada su capacidad de modelar dependencias de largo plazo y capturar patrones complejos en secuencias.

## LSTM

Poseen una puerta de entrada que regula el flujo de nueva información. Así mismo, tienen otro componente llamado la puerta de olvido, que determina qué información se descarta y qué información se queda. Finalmente, tienen una puerta de salida que controla la información que se emite (Schmidt, 2019) [4].

## LSTM Bidireccional

Son una arquitectura de red neuronal recurrente capaz de procesar datos secuenciales tanto hacia adelante como hacia atrás. Están compuestas por dos redes LSTM, una que procesa la secuencia de entrada en la dirección hacia adelante y otra que procesa la secuencia de entrada en la dirección hacia atrás (Zvornicanin & Zvornicanin, 2024) [5].



**Fuente:** Schmidt, R. M. (2019). Recurrent Neural Networks (RNNs): A gentle Introduction and Overview. arXiv (Cornell University). <https://doi.org/10.48550/arxiv.1912.05911>  
Zvornicanin, E., & Zvornicanin, E. (2024, 18 marzo). Differences Between Bidirectional and Unidirectional LSTM | Baeldung on Computer Science. Baeldung On Computer Science. <https://www.baeldung.com/cs/bidirectional-vs-unidirectional-lstm>

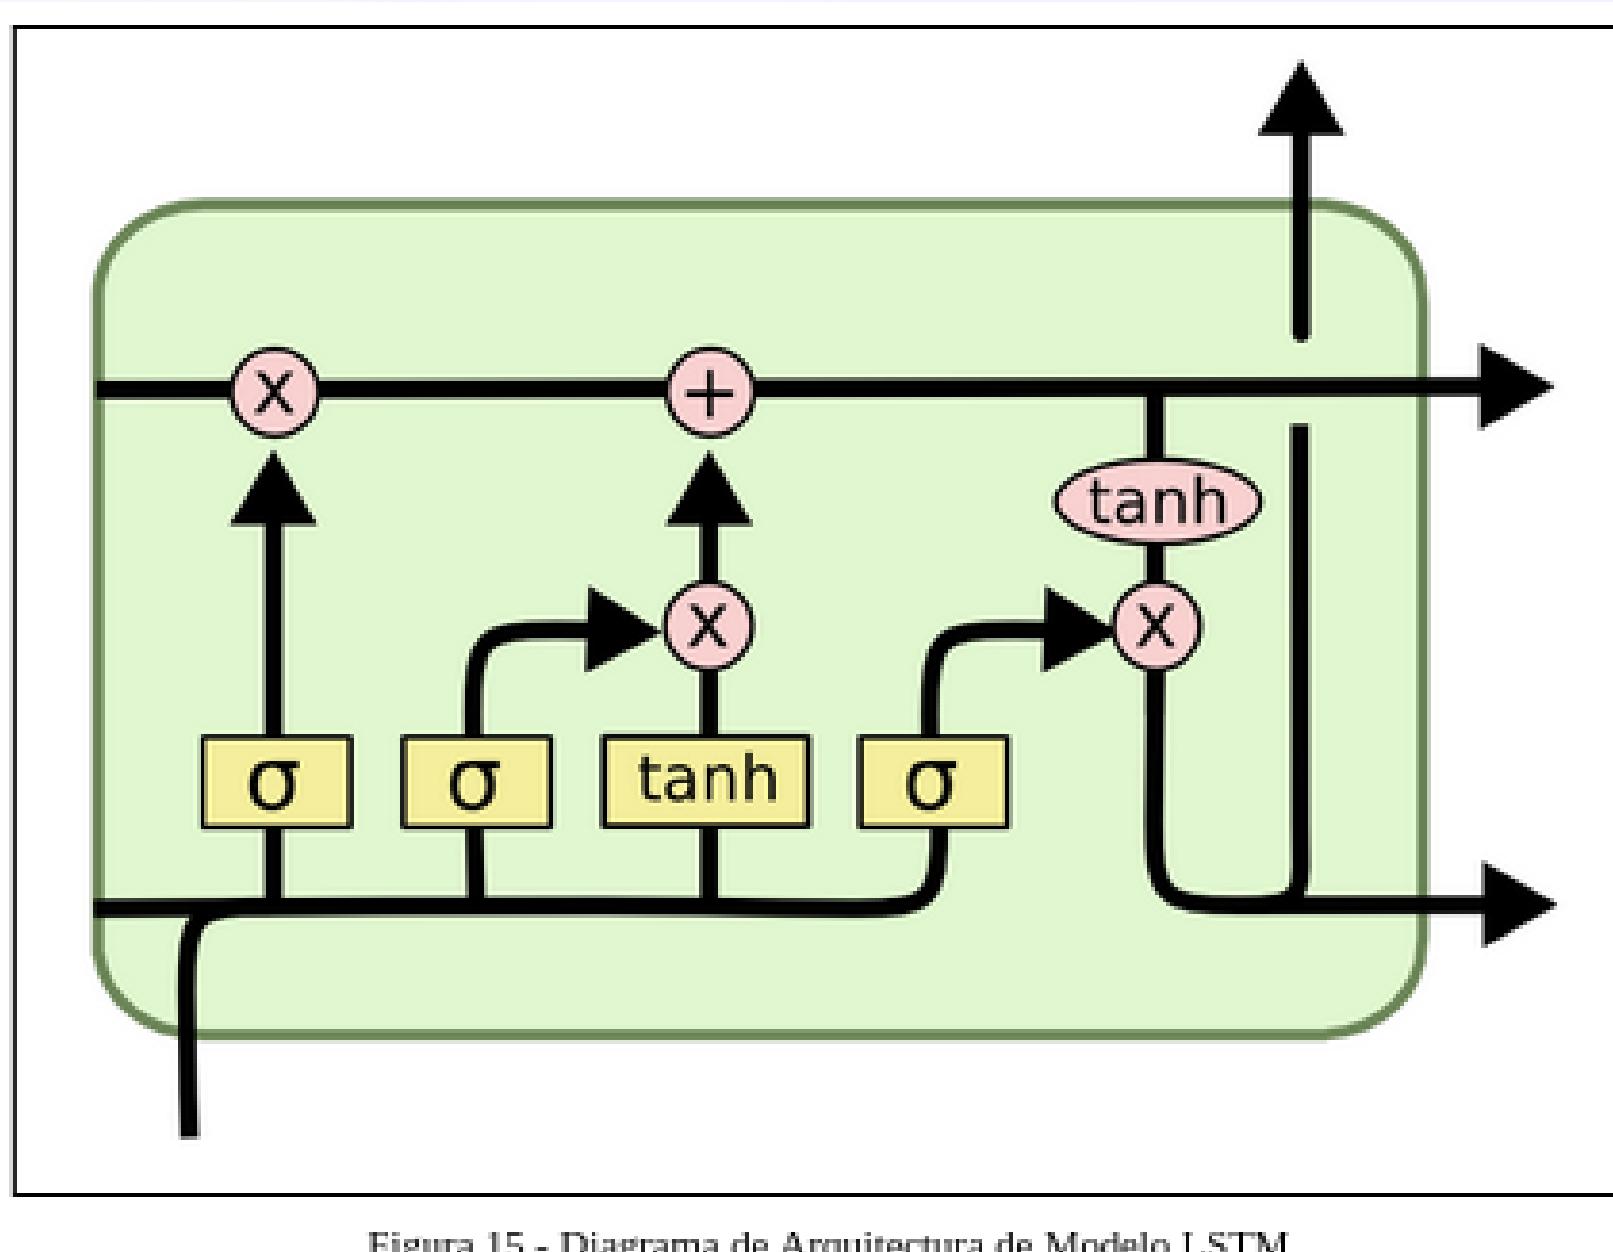


Figura 15 - Diagrama de Arquitectura de Modelo LSTM

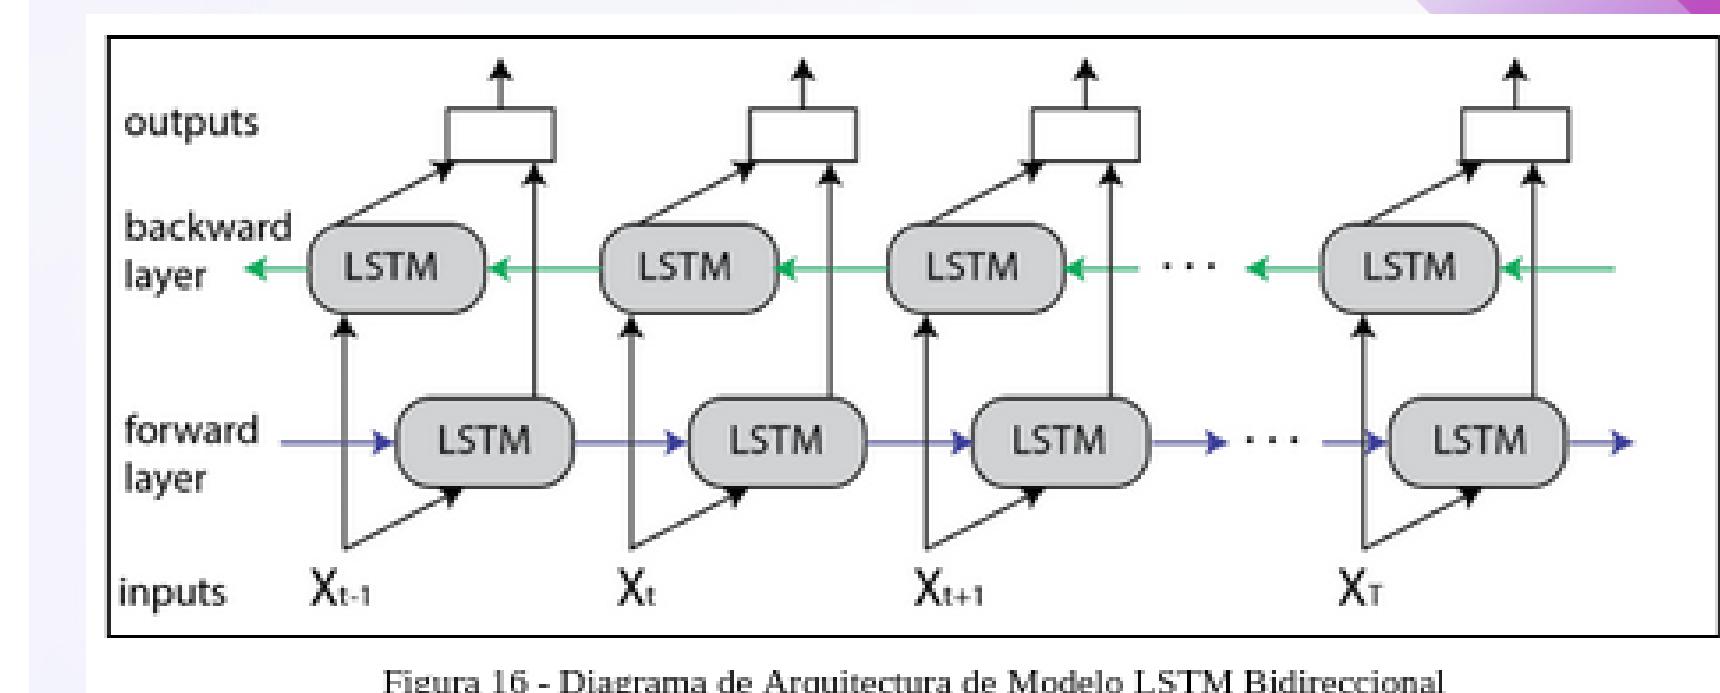


Figura 16 - Diagrama de Arquitectura de Modelo LSTM Bidireccional

# DESCRIPCIÓN DE SOLUCIÓN

Model: "sequential"		
Layer (type)	Output Shape	Param #
lstm (LSTM)	(None, 80, 128)	86816
dropout (Dropout)	(None, 80, 128)	0
batch_normalization (Batch Normalization)	(None, 80, 128)	512
lstm_1 (LSTM)	(None, 80, 64)	49408
dropout_1 (Dropout)	(None, 80, 64)	0
batch_normalization_1 (Batch Normalization)	(None, 80, 64)	256
lstm_2 (LSTM)	(None, 80, 32)	12416
dropout_2 (Dropout)	(None, 80, 32)	0
batch_normalization_2 (Batch Normalization)	(None, 80, 32)	128
dense (Dense)	(None, 80, 1)	33
<hr/>		
Total params: 148769 (581.13 KB)		
Trainable params: 148321 (579.38 KB)		
Non-trainable params: 448 (1.75 KB)		

Figura 17 - Arquitectura de Modelo LSTM Tradicional.

Model: "sequential"		
Layer (type)	Output Shape	Param #
bidirectional (Bidirectional)	(None, 80, 256)	181248
dropout (Dropout)	(None, 80, 256)	0
batch_normalization (Batch Normalization)	(None, 80, 256)	1024
bidirectional_1 (Bidirectional)	(None, 80, 128)	164352
dropout_1 (Dropout)	(None, 80, 128)	0
batch_normalization_1 (Batch Normalization)	(None, 80, 128)	512
bidirectional_2 (Bidirectional)	(None, 80, 64)	41216
dropout_2 (Dropout)	(None, 80, 64)	0
batch_normalization_2 (Batch Normalization)	(None, 80, 64)	256
dense (Dense)	(None, 80, 1)	65
<hr/>		
Total params: 388673 (1.48 MB)		
Trainable params: 387777 (1.48 MB)		
Non-trainable params: 896 (3.50 KB)		

Figura 18 - Arquitectura de Modelo LSTM Bidireccional.

# ANÁLISIS DE RESULTADOS

## MODELO LSTM TRADICIONAL

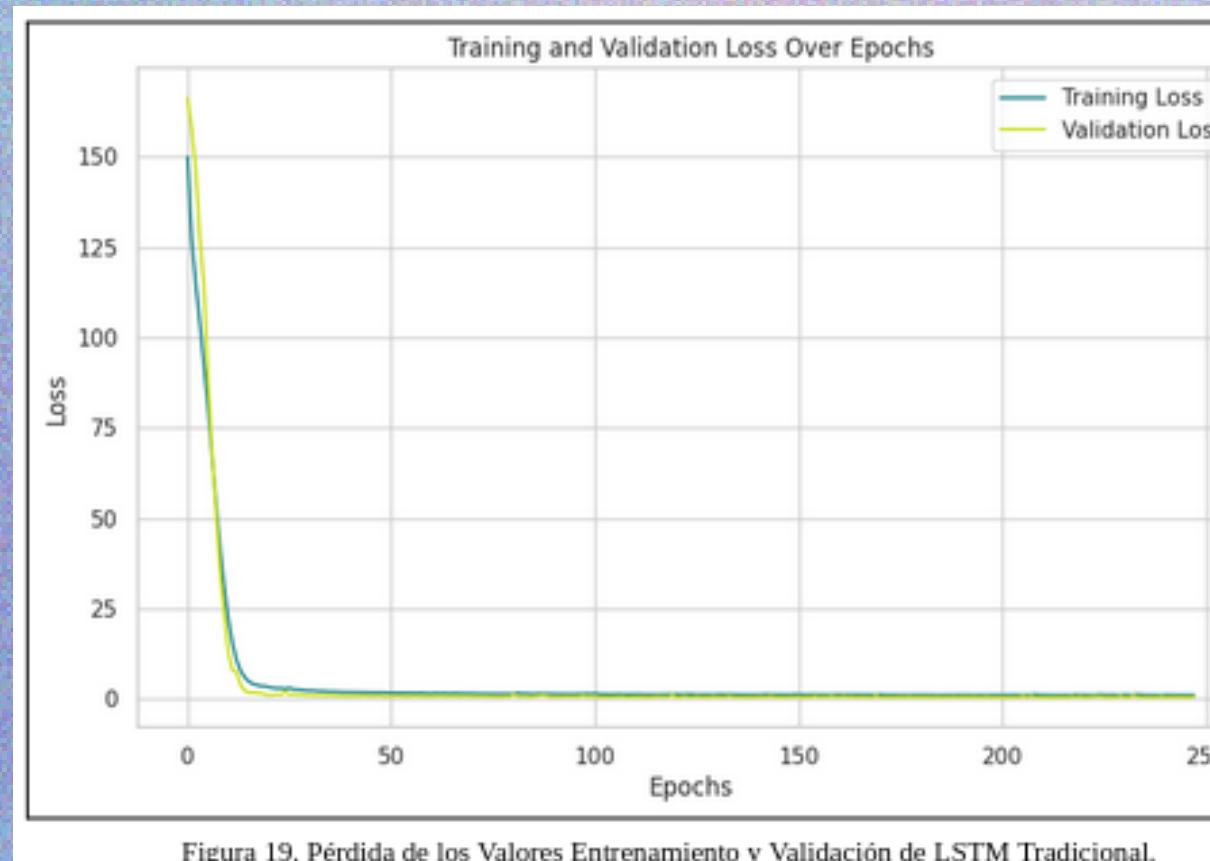


Figura 19. Pérdida de los Valores Entrenamiento y Validación de LSTM Tradicional.

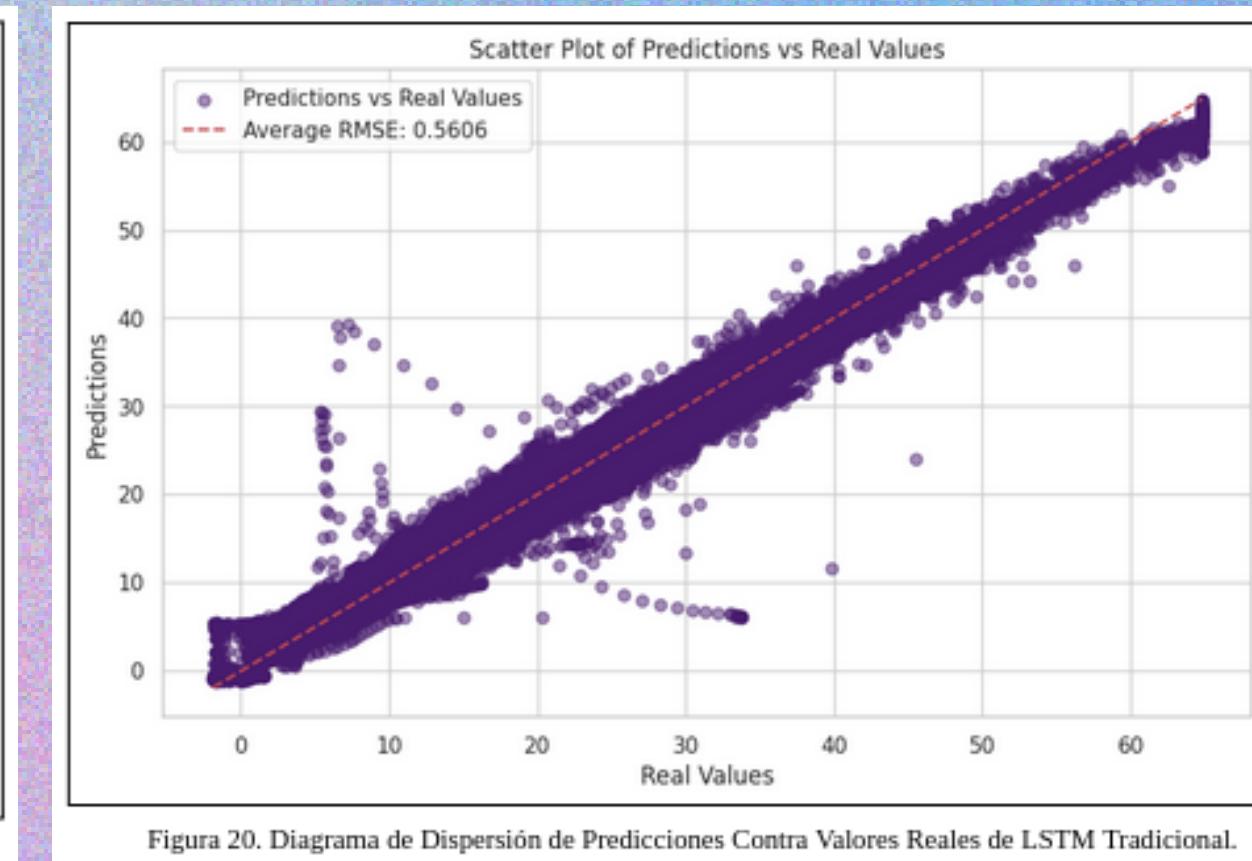


Figura 20. Diagrama de Dispersión de Predicciones Contra Valores Reales de LSTM Tradicional.

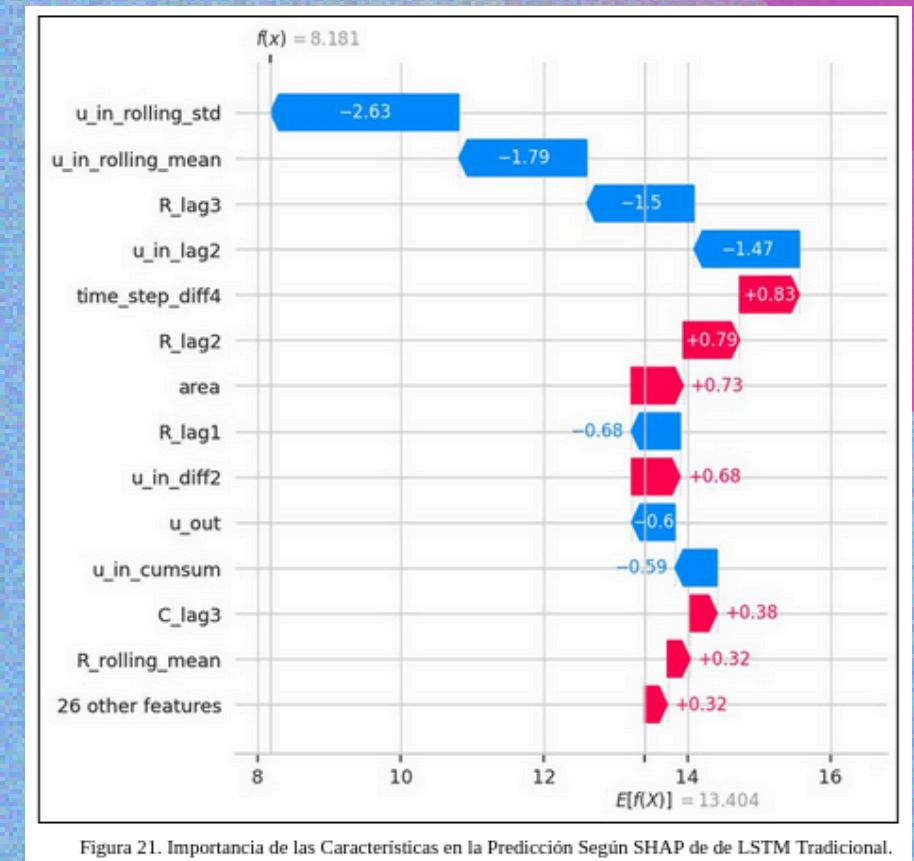


Figura 21. Importancia de las Características en la Predicción Según SHAP de de LSTM Tradicional.

# ANÁLISIS DE RESULTADOS

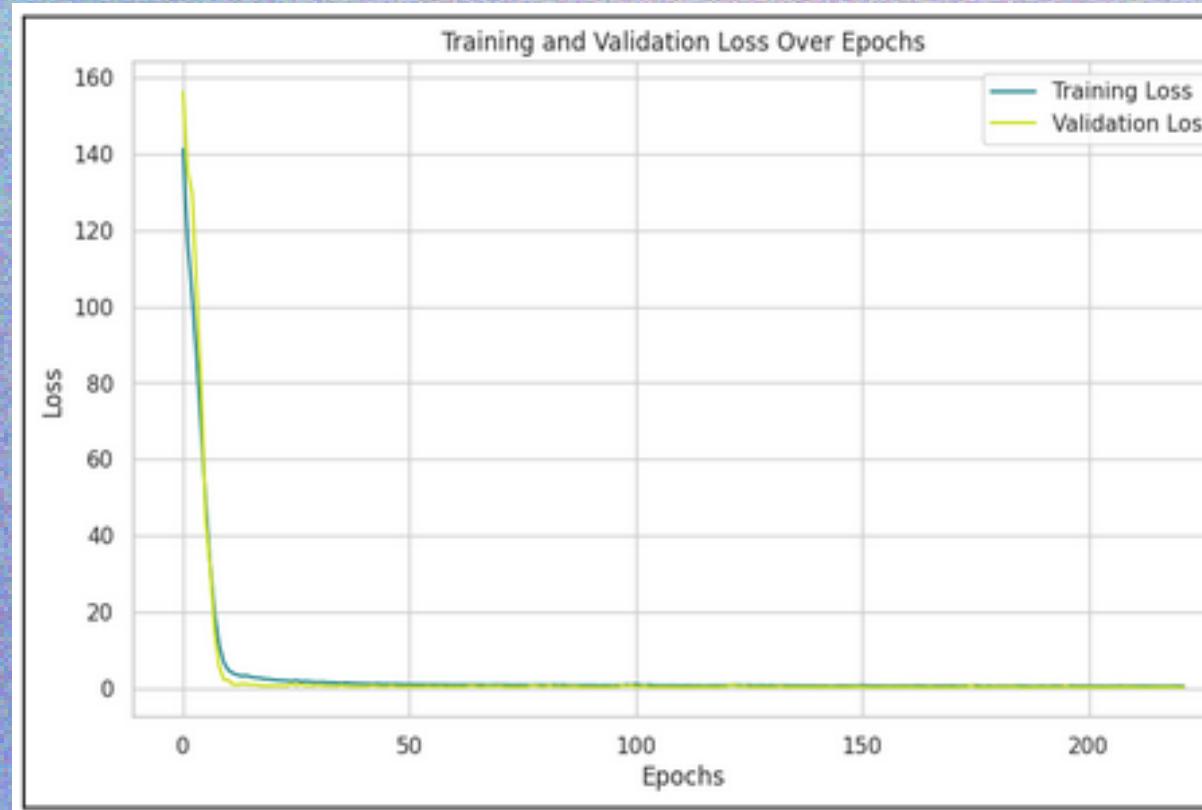


Figura 19. Pérdida de los Valores Entrenamiento y Validación de LSTM Bidireccional.

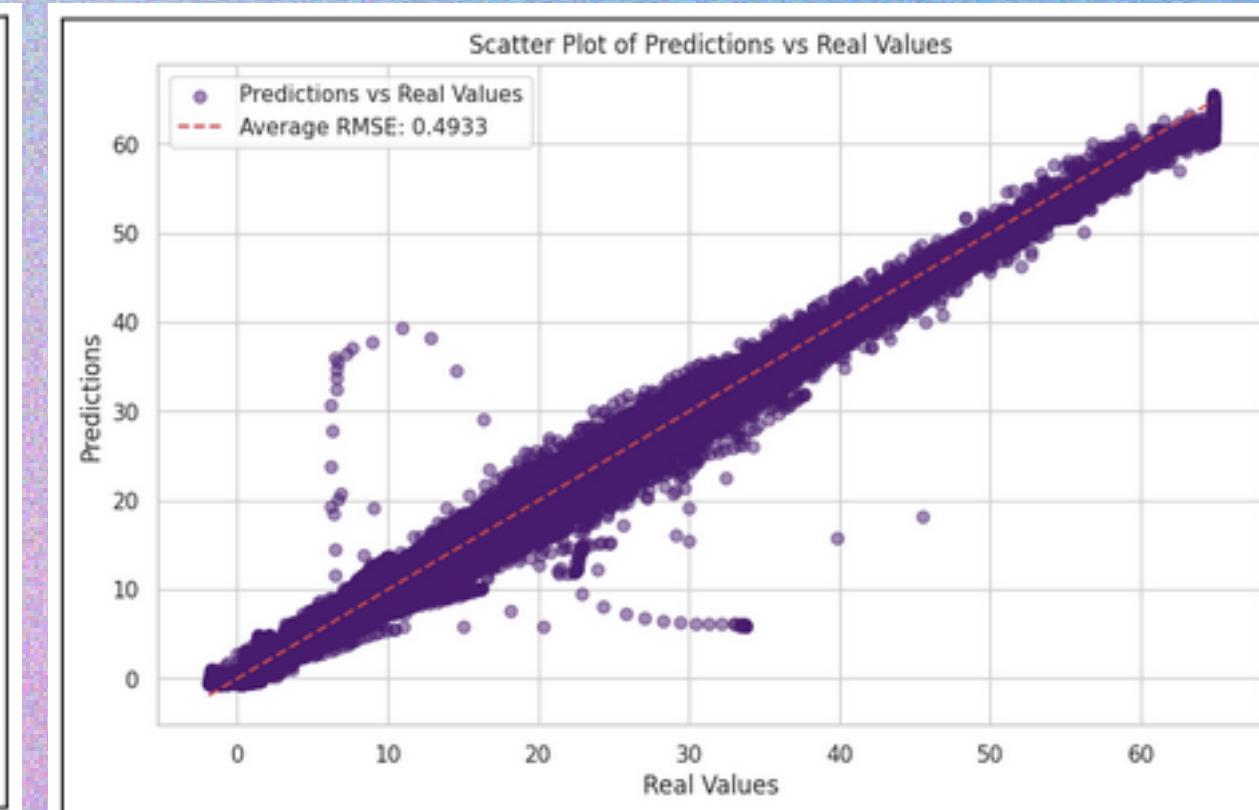


Figura 23. Diagrama de Dispersión de Predicciones Contra Valores Reales de LSTM Bidireccional.

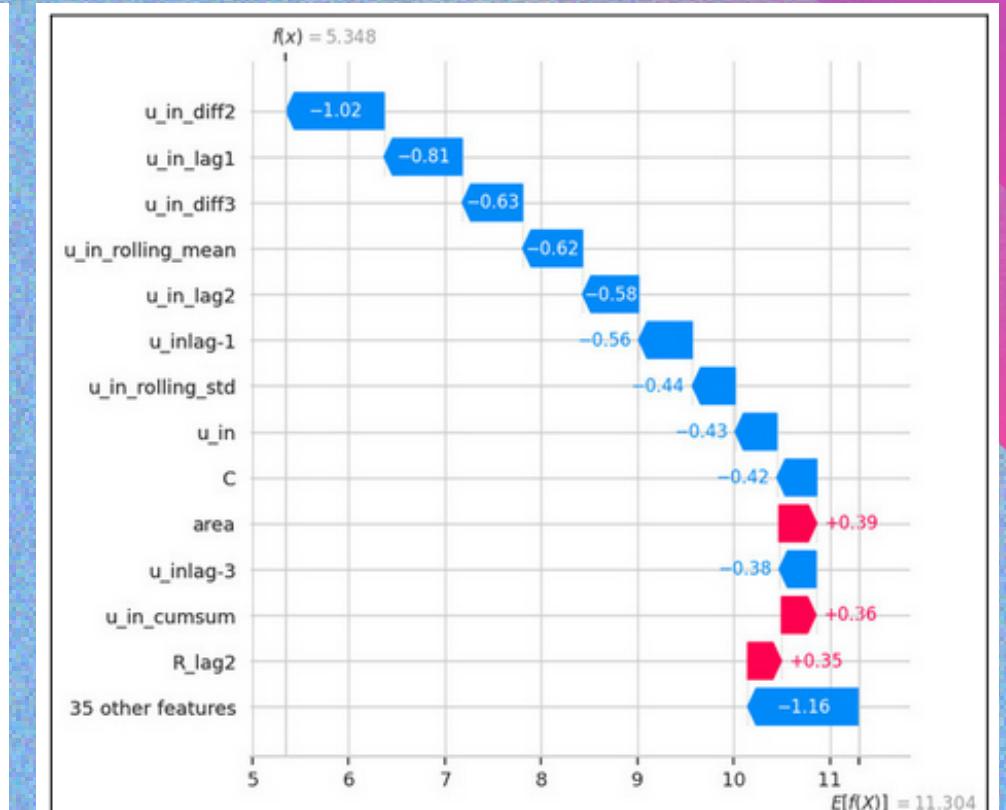


Figura 24. Importancia de las Características en la Predicción Según SHAP de de LSTM Bidireccional.

# COMPARACIÓN DE DESEMPEÑOS

Autores	Arquitectura	MAE
Alam et al. [17]	Bi-LSTM and Bi-GR	0.145
Abdelghani Belgaïd [18]	ResBiLSTM	0.15
Este trabajo	Bi-LSTM	0.24
Este trabajo	LSTM	0.31
Wadne et al. [19]	RNN	0.33

Cuadro 4 - Análisis Comparativo de Desempeños de Arquitecturas

# CONCLUSIONES DE ESTUDIO

El mejor desempeño corresponde a la BiLSTM con un RMSE de 0.4933 y un MAE de tan solo 0.24.

Modificaciones adicionales en el preprocessamiento podrían optimizar aún más la predicción de la presión.

Se recomienda realizar variaciones en el patience del early stopping, dado que este afecta el comportamiento de modelos durante el entrenamiento.

Aún existe margen de mejora. Se recomienda experimentar con distintos métodos de preprocessamiento de datos y con arquitecturas recurrentes más complejas

# REFERENCIAS BIBLIOGRÁFICAS

---

- [1] Uddin, R., Ali, A. H., Kazmi, S. M. H., & Akbar, M. (2023). Rapid Design of an ICU Ventilator: An Approach Based on Smart Switching of Compressed Air-Oxygen. *IEEE Transactions On Biomedical Circuits And Systems*, 18(1), 63-75. <https://doi.org/10.1109/tbcas.2023.3307441>
- [2] Diao, S., Wei, C., Wang, J., & Li, Y. (2024). Ventilator pressure prediction using recurrent neural network. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2410.06552>
- [3] Suo, D., Agarwal, N., Xia, W., Chen, X., Ghai, U., Yu, A., Gradu, P., Singh, K., Zhang, C., Minasyan, E., LaChance, J., Zajdel, T., Schottdorf, M., Cohen, D., & Hazan, E. (2021). Machine Learning for Mechanical Ventilation Control. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2102.06779>
- [4] Schmidt, R. M. (2019). Recurrent Neural Networks (RNNs): A gentle Introduction and Overview. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1912.05911>
- [5] Zvornicanin, E., & Zvornicanin, E. (2024, 18 marzo). Differences Between Bidirectional and Unidirectional LSTM | Baeldung on Computer Science. *Baeldung On Computer Science*. <https://www.baeldung.com/cs/bidirectional-vs-unidirectional-lstm>
- [6] Alam, M. J., Rabbi, J., & Ahamed, S. (2023). Forecasting Pressure Of Ventilator Using A Hybrid Deep Learning Model Built With Bi-LSTM and Bi-GRU To Simulate Ventilation. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2302.09691>
- [7] Abdelghani Belgaid. Deep Sequence Modeling for Pressure Controlled Mechanical Ventilation. *medRxiv*, 2022.
- [8] Dr. Vinod Wadne et al. Pressure prediction system in lung circuit using deep learning and machine learning. *International Research Journal of Engineering and Technology (IRJET)*, 0, 9, May 2022